

中风风险数据探索分析报告

基于 5110 条医疗记录的数据分析与统计检验

报告摘要

本报告对包含 5110 条记录的医疗数据集进行了系统分析。经过数据清洗（填充 28.1 为 BMI 中位数，删除 id 列，统一汉化合并取值），得到 11 个有效分析字段。

数据集共 249 名中风患者，整体中风率 4.87%。通过卡方检验和 Mann-Whitney U 检验，识别出年龄、心脏病、高血压、血糖为中风的最显著风险因素。

一、数据基础体检

数据集共 5110 条记录，预处理后保留 11 个字段。中风患者共 249 人，整体中风率 4.87%。吸烟状态中"未知"占 1544 条 (30.2%)，分析吸烟时单独过滤处理。

预处理步骤：

- 删除无意义列 id
- BMI 缺失值 (201 个) 以中位数 28.1 填充
- 所有列名及分类取值统一汉化 (性别 / 职业 / 曾婚 / 居住类型 / 吸烟)
- 年龄分组 (未成年/青年/中年/老年)、血糖分组 (正常/偏高)、BMI 分组 (偏瘦/正常/超重/肥胖)

二、三条核心结论 (含统计检验)

结论 1：年龄越大，中风比例越高

按年龄段分组，老年(≥ 60 岁)中风率高达 13.15%，未成年(< 18 岁)仅为 0.23%，呈现极显著正相关。

年龄段	样本数	中风人数	中风率
未成年(< 18)	856	2	0.23%
青年(18~40)	1314	6	0.46%
中年(40~60)	1564	60	3.84%
老年(≥ 60)	1376	181	13.15%

► 卡方检验： $\chi^2 = 302.23$, $p < 0.001$ ，年龄与中风存在极显著的统计学关联。未中风组平均年龄 42.0 岁，中风组 67.7 岁 (MW-U 检验 $p < 0.001$)。

结论 2：心脏病显著提升中风风险

有心脏病者中风率 17.03%，无心脏病者 4.18%，前者约为后者的 4.1 倍，提示心血管系统的整体风险联动。

心脏病	样本数	中风人数	中风率
无心脏病	4834	202	4.18%
有心脏病	276	47	17.03%

► 卡方检验： $\chi^2 = 90.26$, $p < 0.001$ ，心脏病与中风存在极显著的统计学关联。

结论 3 · 吸烟与中风率的关系

过滤掉 1544 条"未知"记录后（占 30.2%，平均年龄 30.2 岁，中风率 3.04%），已戒烟者中风率 7.91% 反高于当前吸烟者 5.32%，从不吸烟者最低 4.76%。已戒烟组平均年龄 54.9 岁，远高于不吸组（46.7 岁）和当前吸烟组（47.1 岁），年龄分层后同年龄段内三组差异大幅缩小，年龄是主要混淆变量。

吸烟	样本数	中风人数	中风率
不吸	1892	90	4.76%
吸烟	789	42	5.32%
已戒	885	70	7.91%

► 卡方检验： $\chi^2 = 29.15$, $p < 0.001$ ，但年龄分层后效应减弱。

三、统计检验结果汇总

对全部可用变量做了卡方检验（分类变量）和 Mann-Whitney U 检验（数值变量）：

检验	方法	χ^2	p值	U统计量	未中风均值	中风均值
年龄段 × 是否中风	卡方检验	302.23	0.0000	-	-	-
心脏病 × 是否中风	卡方检验	90.26	0.0000	-	-	-
高血压 × 是否中风	卡方检验	81.61	0.0000	-	-	-
性别 × 是否中风	卡方检验	0.47	0.7895	-	-	-
曾婚 × 是否中风	卡方检验	58.92	0.0000	-	-	-
职业 × 是否中风	卡方检验	49.16	0.0000	-	-	-
居住类型 × 是否中风	卡方检验	1.08	0.2983	-	-	-
吸烟 × 是否中风	卡方检验	29.15	0.0000	-	-	-
年龄 × 是否中风	Mann-Whitney U	-	0.000000	200264	41.97	67.73
血糖 × 是否中风	Mann-Whitney U	-	0.000000	471239	104.80	132.54
BMI × 是否中风	Mann-Whitney U	-	0.000277	522642	28.80	30.09

关键发现：

- 年龄 ($\chi^2=302.2$)、心脏病 ($\chi^2=90.3$)、高血压 ($\chi^2=81.6$) 是最显著的中风风险因素
- 性别 ($\chi^2=0.47$, $p=0.790$) 和居住类型 ($\chi^2=1.08$, $p=0.298$) 无显著相关
- 曾婚 ($\chi^2=58.9$) 和职业类型 ($\chi^2=49.2$) 也与中风显著相关，部分受年龄混淆
- 血糖 (MW-U $p<0.001$) 和 BMI (MW-U $p<0.001$) 在中风/未中风组间差异显著

四、关键分析图表

图 4-1：年龄分布与中风




图 4-2：关键分类变量中风率对比




图 4-3：各变量卡方统计量排序




图 4-4：数值变量箱线图（中风 vs 未中风）




图 4-5：关键变量相关系数矩阵

图5：关键变量相关系数矩阵





图 4-6：中风率随年龄变化趋势



五、关键变量汇总统计表

以下为年龄、血糖、BMI、是否中风四列的描述统计 (.describe())：

统计项	年龄	血糖	BMI	是否中风
count	5110.0	5110.0	5110.0	5110.0
mean	43.23	106.15	28.86	0.05
std	22.61	45.28	7.7	0.22
min	0.08	55.12	10.3	0.0
25%	25.0	77.24	23.8	0.0
50%	45.0	91.88	28.1	0.0
75%	61.0	114.09	32.8	0.0
max	82.0	271.74	97.6	1.0

注：本报告基于中风预测数据集（5110 条记录）分析生成。统计检验采用 `scipy.stats`，图表使用 `matplotlib` + `seaborn` 绘制，机器学习模型基于 `scikit-learn`。

风险因素排序：年龄 > 高血压 > 心脏病 > 血糖 > BMI > 曾婚 > 职业 > 吸烟。性别和居住类型无显著统计学关联。

六、机器学习预测建模

为验证风险因素的实际预测能力，构建了两种分类模型：逻辑回归和随机森林。采用 70/30 分层划分训练测试集，使用 `class_weight="balanced"` 处理类别不平衡问题。

模型评估

逻辑回归 AUC = 0.84 (CV: 0.84 ± 0.01)，召回率 78.7%——更擅长识别中风高风险人群。随机森林 AUC = 0.80 (CV: 0.80 ± 0.01)，准确率 86.2%——整体分类更准确但召回偏低。随机森林特征重要性显示：年龄 (44.2%)、血糖 (15.9%)、BMI (15.3%) 为 Top 3 预测因子，与统计检验结论一致。

图 6-1：ROC 曲线对比




图 6-2：混淆矩阵对比

图 8：混淆矩阵对比





图 6-3：随机森林特征重要性 (Top 15)



七、完整特征分析

高血压 —— 被低估的风险因素

数据中 498 人 (9.7%) 患有高血压，其中风率 13.86%，为无高血压者 (3.92%) 的 3.5 倍。高血压组平均年龄 62.4 岁，无高血压组 41.2 岁，提示高血压与年龄高度共线。卡方检验 $\chi^2=81.6$ ($p<0.001$)，关联极为显著，但在年龄分层后效应有所减弱。

血糖 —— 第二重要的数值预测因子

以 125 mg/dL 为界，偏高组 (1000 人) 中风率 10.00%，正常组 (4110 人) 仅 3.63%。Mann-Whitney U 检验 $p<0.001$ 。血糖偏高者平均年龄也更高 (57.0 vs 39.9 岁)，但与年龄相关性弱于高血压 ($r=0.23$)。

曾婚状态 —— 年龄代理变量

曾婚组中风率 6.5%，未曾婚组 1.8% ($\chi^2=58.9$, $p<0.001$)，但曾婚组平均年龄 52.2 岁而未曾婚组仅 26.2 岁。年龄分层后两组差异大幅缩小，曾婚实为年龄的代理变量。

性别和居住类型 —— 无显著关联

性别 ($p=0.790$) 和居住类型 ($p=0.298$) 与中风风险无显著统计学关联，可在预测建模中作为弱特征或直接排除。

八、结论与建议

核心结论

- 年龄是最强的中风预测因子：老年组 (≥ 60 岁) 中风率 13.15%，是未成年组的 57 倍。随机森林模型中年龄贡献了 44.2% 的特征重要性。
- 心血管健康三联征（高血压+心脏病+高血糖）显著增加风险：三项指标的 χ^2 值分别为 81.6、90.3 和统计显著。
- 吸烟的独立效应有限：已戒烟者中风率 (7.9%) 高但平均年龄大 (54.9 岁)，年龄分层后吸烟的独立效应大幅减弱。
- 性别和城乡差异与中风无显著关联：可排除这两个维度作为主要风险因素。
- 机器学习模型 (LR AUC=0.84) 确认了上述风险因素，为临床筛查提供了量化工具。

建议

筛查重点：对 60 岁以上、有高血压/心脏病史、血糖偏高的人群优先中风风险评估。

干预方向：血压控制、血糖管理、心脏健康维护是最具成本效益的预防措施。

模型应用：逻辑回归模型可作为初筛工具，以 78.7% 的召回率识别高风险个体。

数据改进：吸烟数据 30% 为“未知”，建议在数据采集环节加强信息完整性。

— 报告完 —

本报告所有代码和分析可复现，详见项目源代码。